

Deep Learning 1 — Übungsklausur 1

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort pro Frage ist korrekt.

1. Was ist eine Gate-Funktion in einem LSTM?

- (a) Eine Softmax-Aktivierung über alle Zeitschritte
- (b) Eine Multiplikation mit einer Sigmoid-Aktivierung
- (c) Eine ReLU-Aktivierung der Hidden States
- (d) Eine lineare Projektion des Inputs

2. Wie viele Parameter (Gewichte + Bias) hat `torch.nn.Conv2d(3, 20, 5)`?

- (a) 1500
- (b) 1520
- (c) 300
- (d) 6020

3. Was beschreibt die Konditionszahl der Hessematrix?

- (a) Die Lernrate des Optimierers
- (b) Das Verhältnis von größtem zu kleinstem Eigenwert – ein Maß für die Konvergenzgeschwindigkeit von Gradientenabstieg
- (c) Die Anzahl der Trainingsiterationen bis zur Konvergenz
- (d) Den Abstand zwischen Trainings- und Testfehler

4. Der Perceptron-Algorithmus entspricht Gradientenabstieg auf welchem Loss?

- (a) Squared Loss
- (b) Log-Loss
- (c) Perceptron Loss $\max(0, -y \cdot t)$
- (d) Hinge Loss

5. Welche Operation führt zu translationaler Invarianz in einem CNN?

- (a) Faltung (Convolution)
- (b) Batch Normalization
- (c) Pooling
- (d) Residual Connection

6. Was ist der Vorteil von zentrierten Daten vor dem Training?

- (a) Die Gradienten werden exakt null
- (b) Die Konditionszahl der Hessematrix verbessert sich ($\rightarrow 1$), was schnellere Konvergenz garantiert
- (c) Das Modell benötigt weniger Parameter
- (d) Dropout wird überflüssig

7. Was versteht man unter 'Double Descent'?

- (a) Zwei lokale Minima im Verlust
- (b) Der Generalisierungsfehler sinkt erneut, wenn die Modellkomplexität sehr groß wird
- (c) Gradientenabstieg mit zwei verschiedenen Lernraten
- (d) Eine Regularisierungsstrategie für tiefe Netze

8. Welche Aussage über Dropout ist korrekt?

- (a) Dropout multipliziert jeden Eingang mit einer Bernoulli-Zufallsvariablen
- (b) Dropout erhöht deterministisch die Gewichte
- (c) Dropout wird nur beim Testing angewendet
- (d) Dropout ersetzt die Aktivierungsfunktion

2 Theorie (20 Punkte)

Gegeben sei ein einfaches RNN mit Input-Sequenz $(x_1, x_2) \in \mathbb{R}^n$, Gewicht $w \in \mathbb{R}^n$ und $h_0 = 0$:

$$h_1 = \tanh(x_1 \cdot w + h_0)$$

$$h_2 = \tanh(x_2 \cdot w + h_1)$$

$$y = h_2, E = (y - t)^2$$

(a)

Zeichnen Sie den annotierten Berechnungsgraphen des Netzwerks. (5 Pkt.)

Antwort:

(b)

Berechnen Sie $\partial E / \partial y$. (3 Pkt.)

Antwort:

(c)

Geben Sie die Kettenregel für $\partial E / \partial w$ an. Verwenden Sie ∂^+ für direkte Ableitungen. (7 Pkt.)

Antwort:

(d)

Berechnen Sie $\partial E / \partial w$ explizit. (5 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie folgende Verlustfunktionen für Regression:

(a)

Formulieren Sie Vor- und Nachteile des Squared Loss $\mathcal{L}(y, t) = (y - t)^2$ im Vergleich zum Absolute Loss $\mathcal{L}(y, t) = |y - t|$. (8 Pkt.)

Antwort:

(b)

Was ist der Log-Cosh Loss? Schreiben Sie die Formel auf und erläutern Sie warum er einen Vorteil gegenüber MAE und MSE bietet. (6 Pkt.)

Antwort:

(c)

Erklären Sie den Zusammenhang zwischen Maximum-Likelihood-Schätzung und dem Squared Loss. Welche Verteilung liegt dem Squared Loss zugrunde? (6 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie Regularisierung und Modellkomplexität:

(a)

Erklären Sie Weight Decay. Wie beeinflusst der Parameter λ das Modellverhalten? (5 Pkt.)

Antwort:

(b)

Was ist Early Stopping? Beschreiben Sie den Algorithmus und warum er Regularisierung bewirkt. (5 Pkt.)

Antwort:

(c)

Was sind spurious correlations? Nennen Sie ein konkretes Beispiel und beschreiben Sie zwei Methoden, um damit umzugehen. (10 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

Schreiben Sie PyTorch-Code für folgende Aufgaben:

(a)

Implementieren Sie eine einfache CNN-Klasse in PyTorch mit: zwei Conv2d-Schichten (3→16, 16→32, Kernel 3×3), ReLU-Aktivierungen, MaxPool2d nach jeder Conv-Schicht, und einem abschließenden Linear-Layer für 10 Klassen. (12 Pkt.)

Antwort:

(b)

Erklären Sie, wie man den Trainings-Loop für dieses Netz strukturiert (Pseudo-Code reicht). Welche Schritte sind zwingend notwendig? (8 Pkt.)

Antwort:
