

Deep Learning 1 — Übungsklausur 2

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort pro Frage ist korrekt.

1. Was ist Translation Equivariance bei CNNs?

- (a) $f(T(x)) = T(f(x))$ — eine Translation am Eingang erzeugt dieselbe Translation am Ausgang
- (b) $f(T(x)) = f(x)$ — der Ausgang ändert sich nicht bei Translation
- (c) Das Netz ist invariant gegenüber Rotation
- (d) Pooling macht das Netz equivariant

2. Welche Aussage über LSTMs ist korrekt?

- (a) LSTMs haben zwei Zustände: hidden state h und cell state c
- (b) LSTMs haben nur einen Hidden State
- (c) LSTMs verwenden keine Gating-Mechanismen
- (d) LSTMs lösen das Vanishing-Gradient-Problem vollständig

3. Was beschreibt die VC-Dimension?

- (a) Die Anzahl der Trainingsbeispiele
- (b) Ein Maß für die Komplexität/Kapazität eines Modells
- (c) Die Validierungsgenauigkeit
- (d) Den Verlust auf dem Testset

4. Was ist der Unterschied zwischen Autoencoder und PCA?

- (a) PCA lernt nichtlineare Repräsentationen, Autoencoder lineare
- (b) Autoencoder können nichtlineare Repräsentationen lernen, PCA nur lineare
- (c) Beide sind äquivalent
- (d) PCA benötigt mehr Parameter

5. Was ist Sparse Coding?

- (a) Daten werden als Vektor mit vielen Nullelementen repräsentiert
- (b) Daten werden durch dichte Vektoren beschrieben
- (c) Eine Regularisierungsmethode mit L2-Norm
- (d) Ein Verfahren zur Dimensionsreduktion via PCA

6. Welche Norm wird als Approximation der L0-Norm in Sparse Coding verwendet?

- (a) L2-Norm
- (b) L_∞ -Norm
- (c) L1-Norm
- (d) Frobenius-Norm

7. Was ist Transferlernen?

- (a) Gewichte eines trainierten Netzwerks auf verwandte Aufgaben übertragen
- (b) Training von zwei Netzwerken gleichzeitig
- (c) Ein Verfahren zur Datenaugmentation
- (d) Das Netz auf Testdaten anpassen

8. Welche Aussage über Backpropagation durch die Zeit (BPTT) ist korrekt?

- (a) Die Gradienten werden vorwärts durch die Zeit propagiert
- (b) Lange Produktketten von Gradienten können zu Vanishing oder Exploding Gradients führen
- (c) BPTT funktioniert ohne Kettenregel
- (d) BPTT ist nur für lineare RNNs definiert

2 Theorie (20 Punkte)

Gegeben sei ein Netz mit Inputs $x_1, x_2 \in \mathbb{R}$ und Output y :

$$z_1 = \max(0, x_1 + x_2)$$

$$z_2 = \max(0, x_1 - x_2)$$

$$y = z_1 + z_2$$

(a)

Die Funktion ist stückweise linear. Schreiben Sie die vier Gebiete auf, in denen die Funktion linear ist, und skizzieren Sie diese in einem Koordinatensystem. (8 Pkt.)

Antwort:

(b)

Geben Sie für jedes Gebiet die Gleichung der Entscheidungsgrenze $y = 1$ an und zeichnen Sie diese. (8 Pkt.)

Antwort:

(c)

Ist diese Funktion überall differenzierbar? Begründen Sie kurz. (4 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie Convolutional Neural Networks:

(a)

Was ist der Unterschied zwischen Convolution und Cross-Correlation? Welche Operation implementieren PyTorch-Conv-Layer tatsächlich? (6 Pkt.)

Antwort:

(b)

Erklären Sie die Idee von Residual Connections (ResNet). Schreiben Sie die Update-Gleichung auf und erläutern Sie den Vorteil für den Gradientenfluss. (8 Pkt.)

Antwort:

(c)

Beschreiben Sie einen typischen CNN-Blueprint für Klassifikation. Welche Rolle spielen Global Average Pooling und der abschließende MLP? (6 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie Autoencoderarchitekturen:

(a)

Was ist ein Denoising Autoencoder? Schreiben Sie das Optimierungsziel auf und erläutern Sie, welche Invarianz er lernt. (8 Pkt.)

Antwort:

(b)

Wie kann man Anomalieerkennung mit einem Autoencoder durchführen? Beschreiben Sie das Vorgehen Schritt für Schritt. (7 Pkt.)

Antwort:

(c)

Welchen Tradeoff kontrolliert die Bottleneck-Dimension eines Autoencoders? (5 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

Adversarielle Beispiele:

(a)

Schreiben Sie PyTorch-Code, der ein adversariales Beispiel erzeugt. Der Optimizer soll SGD sein. Der Input z wird optimiert, um folgendes Ziel zu minimieren: $\min_z \|x - z\|^2 + \max(0, 1 + t \cdot f(z))$. Argumente: Datenpunkt x , Ziel t , Modell f . (12 Pkt.)

Antwort:

(b)

Wie müssen Sie den Code minimal anpassen, um mit einem Batch von Input-Target-Paaren zu arbeiten? (Keine zusätzlichen For-Schleifen.) (4 Pkt.)

Antwort:

(c)

Wie nutzt man adversariale Beispiele, um das Modell robuster zu machen? (4 Pkt.)

Antwort:
