

Deep Learning 1 — Übungsklausur 3

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort pro Frage ist korrekt.

1. Was ist der Unterschied zwischen einem stateful und einem stateless Modell?

- (a) Stateless-Modelle sind deterministisch, stateful nicht
- (b) Stateful-Modelle nutzen neben dem Input auch einen internen Zustand für die Vorhersage
- (c) Stateless-Modelle haben mehr Parameter
- (d) Stateful-Modelle können keine Sequenzen verarbeiten

2. Wie lautet die Softmax-Funktion für Klasse i ?

- (a) $p_i = y_i / \sum_j y_j$
- (b) $p_i = \exp(y_i) / \sum_j \exp(y_j)$
- (c) $p_i = \text{sigmoid}(y_i)$
- (d) $p_i = \log(y_i)$

3. Was ist das zentrale Problem bei LRP (Layer-wise Relevance Propagation)?

- (a) LRP kann nur auf linearen Modellen angewendet werden
- (b) Die Propagationsstrategie muss für jede neue Architektur angepasst werden
- (c) LRP liefert immer negative Relevanzwerte
- (d) LRP benötigt doppelt so viele Vorwärtspässe wie normale Inferenz

4. Was versteht man unter Activation Maximization in XAI?

- (a) Das Trainieren des Netzes mit maximaler Lernrate
- (b) Das Finden eines Inputs, der einen bestimmten Neuron maximal aktiviert
- (c) Das Maximieren des Trainingsverlustes
- (d) Die Auswahl der Schicht mit maximaler Aktivierung

5. Welche Verlustfunktion entsteht bei Maximum-Likelihood-Schätzung mit Laplace-Verteilung?

- (a) Squared Loss
- (b) Log-Cosh Loss
- (c) Absolute Loss
- (d) Cross-Entropy

6. Wann stoppen Perceptron-Algorithmen laut Definition zu trainieren?

- (a) Nach einer fixen Anzahl von Epochen
- (b) Sobald alle Trainingsbeispiele korrekt klassifiziert sind
- (c) Wenn der Validierungsfehler minimal wird
- (d) Wenn der Gradient null wird

7. Was ist ein Encoder-Decoder RNN?

- (a) Zuerst wird die Eingangssequenz zu einer globalen Repräsentation s kodiert, danach wird die Ausgangssequenz aus s generiert
- (b) Zwei unabhängige RNNs, die parallel trainiert werden
- (c) Ein RNN mit bidirektionaler Verarbeitung

(d) Ein RNN ohne Hidden State

8. Was beschreibt Dataset Bias?

- (a) Überrepräsentation bestimmter Teile der zugrundeliegenden Verteilung
- (b) Ein zu kleiner Datensatz
- (c) Fehler in den Labels
- (d) Eine falsche Lernrate

2 Theorie (20 Punkte)

Betrachten Sie ein Netz mit Inputs $x \in \mathbb{R}^d$, Parameter c_{ij} , w_j und Output:

$$\begin{aligned} z_{ij} &= |x_i - c_{ij}| \\ a_j &= \exp(-\sum_i z_{ij}) \\ f(x) &= \sum_j w_j a_j \end{aligned}$$

(a)

Berechnen Sie $\partial f / \partial x_i$. (7 Pkt.)

Antwort:

(b)

Zeigen Sie, dass die Gradientennorm beschränkt ist: $\|\partial f / \partial x\|_1 \leq d \cdot \sum_j w_j$. Hinweis: $|\sum_j a_j| \leq \sum_j |a_j|$. (8 Pkt.)

Antwort:

(c)

Wie kann diese obere Schranke genutzt werden, um eine kleine Gradientennorm zu gewährleisten? (5 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie den Cross-Entropy Loss und Log-Loss:

(a)

Schreiben Sie den Cross-Entropy Loss für C Klassen auf. Welche Rolle spielt Softmax? (6 Pkt.)

Antwort:

(b)

Zeigen Sie, dass der binäre Log-Loss $\ell(y, t) = \log(1 + \exp(-y \cdot t))$ äquivalent zur Minimierung von Cross-Entropy ist. (10 Pkt.)

Antwort:

(c)

Was ist der Vorteil des Log-Loss gegenüber dem Perceptron Loss bezüglich Generalisierung? (4 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie Mixture Density Networks (MDNs) und inverse Probleme:

(a)

Was ist ein inverses Problem? Geben Sie ein konkretes Beispiel. (5 Pkt.)

Antwort:

(b)

Wie modelliert ein MDN die bedingte Wahrscheinlichkeit $p(t|x)$? Schreiben Sie die Formel auf. (8 Pkt.)

Antwort:

(c)

Welches Ausgabe-Vektor gibt ein MDN aus und welche Aktivierungsfunktionen werden auf welche Komponenten angewendet? (7 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

Sparse Coding und Autoencoder:

(a)

Schreiben Sie das Optimierungsziel für lineares Sparse Coding mit L1-Regularisierung und Gewichtsregularisierung auf. Erläutern Sie jeden Term. (8 Pkt.)

Antwort:

(b)

Warum reicht die L1-Regularisierung alleine nicht aus? Welches Problem entsteht ohne Gewichtsregularisierung? (6 Pkt.)

Antwort:

(c)

Beschreiben Sie den Unterschied zwischen Online- und Batch-Algorithmus für Sparse Coding. Wann ist welcher bevorzugt? (6 Pkt.)

Antwort:
