

Deep Learning 1 — Übungsklausur 4

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort pro Frage ist korrekt.

1. Was versteht man unter dem Receptive Field eines CNN?

- (a) Die Anzahl der Kanäle in einer Schicht
- (b) Das Eingabegebiet, auf das ein Neuron in der Feature Map reagiert
- (c) Die Größe des Kernels
- (d) Die Anzahl der Pooling-Schichten

2. Welche Aussage über Max Pooling ist korrekt?

- (a) Max Pooling ist translationsinvariant innerhalb des Pooling-Fensters
- (b) Max Pooling erhöht die räumliche Auflösung
- (c) Max Pooling hat lernbare Parameter
- (d) Max Pooling führt zu Translation Equivariance

3. Was ist das Ziel von XAI (Explainable AI)?

- (a) Modelle mit möglichst hoher Testgenauigkeit zu bauen
- (b) Vorhersagen eines ML-Modells erklärbar und interpretierbar zu machen
- (c) Die Trainingszeit zu reduzieren
- (d) Adversariale Robustheit zu erhöhen

4. Was sind Shapley Values in ML?

- (a) Gewichte im neuronalen Netz
- (b) Ein Maß für den Beitrag jedes Input-Features zur Vorhersage
- (c) Aktivierungswerte des letzten Layers
- (d) Gradienten des Outputs bezüglich der Parameter

5. Welches Problem löst die Forget Gate in einem LSTM?

- (a) Exploding Gradients
- (b) Steuert, welche Information aus dem Cell State gelöscht werden soll
- (c) Mapping vom Hidden State auf den Output
- (d) Initialisierung der Gewichte

6. Was ist Distribution Shift?

- (a) Das Verschieben von Trainings- und Testdaten in denselben Batch
- (b) Die Tatsache, dass die wahre Verteilung sich über die Zeit verändern kann
- (c) Ein Augmentationsverfahren für Trainingsdaten
- (d) Ein Normalisierungsverfahren für Inputs

7. Welche Aussage über Bidirektionale RNNs ist korrekt?

- (a) Sie verarbeiten die Sequenz zweimal: einmal vorwärts, einmal rückwärts
- (b) Sie können keine Zukunftsinformationen nutzen
- (c) Sie haben weniger Parameter als unidirektionale RNNs
- (d) Sie werden nur für Klassifikation genutzt

8. Was charakterisiert den 0/1-Loss und warum ist er problematisch?

- (a) Er ist differenzierbar, aber sensitiv gegenüber Ausreißern
- (b) Sein Gradient ist fast überall null, wodurch er nicht via Gradientenabstieg optimierbar ist
- (c) Er penalisiert korrekte Vorhersagen
- (d) Er funktioniert nur für multiclass-Klassifikation

2 Theorie (20 Punkte)

Betrachten Sie ein LSTM mit Forget Gate f_g , Input Gate i_g und Output Gate o_g :

(a)

Was ist eine Gate-Funktion mathematisch? Schreiben Sie die allgemeine Form auf. (4 Pkt.)

Antwort:

(b)

Beschreiben Sie die drei Gates (Forget, Input, Output) und ihre jeweilige Operation auf dem Cell State c . (9 Pkt.)

Antwort:

(c)

Wie verbessert der Cell State c im Vergleich zu einem einfachen RNN den Gradientenfluss? Erläutern Sie intuitiv, warum Gradienten weniger aggressiv skaliert werden. (7 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie Gewichtsinitialisierung in tiefen Netzen:

(a)

Zeigen Sie, unter welchen Bedingungen gilt: $\text{Var}(z_i^{(l+1)}) = \text{Var}(z_j^{(l)})$. Welche Initialisierung folgt daraus für die Gewichte? (10 Pkt.)

Antwort:

(b)

Formulieren Sie die Xavier-Initialisierung (Normalverteilung) für eine Schicht mit n Inputs. (5 Pkt.)

Antwort:

(c)

Warum setzen wir die Biases initial auf 0? (5 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie Energy-Based Learning:

(a)

Erklären Sie das Push-Pull-Training für energiebasierte Modelle. (6 Pkt.)

Antwort:

(b)

Was ist der Generalized Perceptron Loss? Schreiben Sie die Formel auf und erläutern Sie, warum er für Generalisierung ungeeignet ist. (7 Pkt.)

Antwort:

(c)

Welches Problem löst das Hinge Loss gegenüber dem Perceptron Loss in energiebasierten Modellen? (7 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

LSTM in PyTorch:

(a)

Schreiben Sie eine PyTorch-Klasse für ein einfaches LSTM-basiertes Sequenzklassifikationsmodell (Encoder-Decoder-Idee): 1 LSTM-Schicht mit `input_size=10`, `hidden_size=64`, dann ein Linear-Layer für 5 Klassen. (12 Pkt.)

Antwort:

(b)

Was muss beim Forward Pass bezüglich des initialen Hidden State h_0 und Cell State c_0 beachtet werden? Nennen Sie zwei mögliche Initialisierungsstrategien. (8 Pkt.)

Antwort:
