

Deep Learning 1 — Übungsklausur 7

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort ist korrekt.

1. Warum sind CNNs anfällig gegenüber adversariellen Perturbationen?

- (a) Weil sie nur auf Texturfeatures reagieren
- (b) Wegen der hohen Dimensionalität des Eingaberaums, die fein abgestimmte Muster erlaubt
- (c) Weil sie keine Residual Connections haben
- (d) Wegen zu wenig Training

2. Was ist der Vorteil von Max Pooling gegenüber Average Pooling?

- (a) Max Pooling hat weniger Parameter
- (b) Max Pooling ist lokal translationsinvariant, da das Maximum im Fenster erhalten bleibt
- (c) Average Pooling ignoriert schwache Aktivierungen
- (d) Max Pooling ist schneller zu berechnen

3. Was ist der Unterschied zwischen Batch und Online Algorithmus bei Sparse Coding?

- (a) Batch aktualisiert W nach jedem Sample, Online nach jedem Batch
- (b) Batch aktualisiert W und alle Sparse Codes in einer Iteration; Online wählt zufällige Samples und aktualisiert W approximativ
- (c) Beide Algorithmen sind äquivalent
- (d) Online-Algorithmus funktioniert nur für kleine N

4. Was ist die freie Energie $F(x, y)$ in einem cRBM?

- (a) Die Energie der sichtbaren Einheiten
- (b) Die Energie nach Marginalisierung über die latenten Variablen h — entspricht einem zweischichtigen neuronalen Netz
- (c) Die Normalisierungskonstante Z
- (d) Die Trainingsverlustfunktion

5. Was ist der Unterschied zwischen stateless und stateful Prediktor für Moving Average?

- (a) Stateless hat unbegrenzten Horizont, stateful begrenzten
- (b) Stateless hat begrenzten Horizont (Schiebefenster), stateful unbegrenzten Horizont mit internem Zustand
- (c) Beide sind äquivalent
- (d) Stateful benötigt mehr Parameter

6. Was misst Predictive Uncertainty bei einem Ensemble von Netzen?

- (a) Den Mittelwert der Vorhersagen
- (b) Die Diskrepanz der Vorhersagen zwischen den Modellen (Standardabweichung der Ensemble-Outputs)
- (c) Den maximalen Loss im Ensemble
- (d) Die Varianz der Gewichte

7. Was versteht man unter einem 'globalen' Effekt bei Boltzmann Machines vs. GMMs?

- (a) GMMs und BMs modellieren beide globale Effekte

- (b) GMMs erfassen lokale Dichteregionen; BMs beschreiben Wahrscheinlichkeiten als Produkt von Faktoren, die globale Effekte erfassen
- (c) BMs sind recheneffizienter als GMMs
- (d) BMs werden nur für lineare Probleme verwendet

8. Wie berechnet man Shapley Values in der Praxis bei großem d?

- (a) Exakt, durch Evaluation auf allen 2^d Feature-Subsets
- (b) Approximativ, durch Mittelung über T zufällig gewählte Permutationen
- (c) Durch Gradientenberechnung
- (d) Durch LRP-Propagation

2 Theorie (20 Punkte)

Betrachten Sie die Herleitung von Gradientenabstieg für Multi-Task Learning:

(a)

Sie haben ein Netz mit $L = 3$ verschiedenen Aufgaben. Schreiben Sie den kombinierten Loss auf. (4 Pkt.)

Antwort:

(b)

Betrachten Sie ein Netz für gleichzeitige binäre Klassifikation (Log-Loss) und Regression (Squared Loss). Schreiben Sie den Gesamt-Loss für einen Datenpunkt auf. (8 Pkt.)

Antwort:

(c)

Welche Herausforderung entsteht beim Trainieren von Multi-Task Netzen? Wie kann man die Gewichtung der einzelnen Tasks festlegen? (8 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie das Problem pathologischer Gradienten in RNNs:

(a)

Formulieren Sie das lineare RNN-Modell als eine Matrixgleichung. (5 Pkt.)

Antwort:

(b)

Erklären Sie, wann Gradienten in linearen RNNs explodieren und wann sie verschwinden. Welchen Eigenwert der Gewichtsmatrix müssen Sie betrachten? (8 Pkt.)

Antwort:

(c)

Beschreiben Sie zwei Maßnahmen, um Exploding/Vanishing Gradients in RNNs zu mildern. (7 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie Predictive Uncertainty:

(a)

Beschreiben Sie Ansatz 1 zur Messung prädiktiver Unsicherheit: Wie wird Unsicherheit explizit im Netz kodiert? (6 Pkt.)

Antwort:

(b)

Beschreiben Sie Ansatz 2 (Ensemble). Was sind μ und σ ? (6 Pkt.)

Antwort:

(c)

Erläutern Sie den Zusammenhang zwischen Unsicherheitsschätzung und dem Gaussian-Mixture-Loss bei Regression. (8 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

Programmieraufgaben zu CNNs:

(a)

Erklären Sie die Ausgabegröße: Gegeben Input 32×32 , Conv2d(3, 16, 5, stride=1, padding=0), dann MaxPool2d(2, stride=2). Was sind die Ausgabedimensionen nach dem Pool? (8 Pkt.)

Antwort:

(b)

Schreiben Sie PyTorch-Code für ResNet-ähnliche Residual Block Klasse mit: zwei Conv2d(64, 64, 3, padding=1), BatchNorm2d, ReLU und Residual Connection. (12 Pkt.)

Antwort:
