

Deep Learning 1 — Übungsklausur 10

Technische Universität Berlin — Deep Learning 1

Gesamtpunkte: 100 | Bearbeitungszeit: 90 Minuten | Alle Hilfsmittel zugelassen

1 Multiple Choice (20 Punkte)

8 Fragen à 2,5 Punkte. Nur eine Antwort ist korrekt.

1. Was ist der Hauptvorteil von CNNs gegenüber MLPs für Bildverarbeitung?

- (a) CNNs haben mehr Parameter
- (b) CNNs nutzen statistische Effizienz durch Parameter-Sharing und Ausnutzung von Nachbarschaftskorrelationen
- (c) CNNs können keine Bilder klassifizieren
- (d) CNNs benötigen mehr Trainingsdaten

2. Welche Aussage über die Log-Loss Verlustfunktion ist korrekt?

- (a) Log-Loss penalisiert nur falsch klassifizierte Punkte
- (b) Log-Loss penalisiert auch korrekt klassifizierte Punkte, die zu nah an der Entscheidungsgrenze sind
- (c) Log-Loss ist identisch mit dem Squared Loss
- (d) Log-Loss hat überall null Gradient

3. Was ist Skip Connection in ResNets formal?

- (a) $x_{l+1} = \text{NN}_l(x_l; \theta_l)$
- (b) $x_{l+1} = x_l + \text{NN}_l(x_l; \theta_l)$
- (c) $x_{l+1} = x_l \cdot \text{NN}_l(x_l; \theta_l)$
- (d) $x_{l+1} = \text{NN}_l(x_l + x_{l-1}; \theta_l)$

4. Was ist der Unterschied zwischen Activation Maximization (global) und Attribution/Heatmap (lokal)?

- (a) Activation Maximization erklärt einzelne Vorhersagen, Heatmaps erklären das gesamte Modell
- (b) Activation Maximization erklärt, was das Modell global gelernt hat; Heatmaps erklären einzelne Vorhersagen
- (c) Beide sind äquivalent
- (d) Heatmaps benötigen keinen Input

5. Welche Aussage zu Spurious Correlations ist korrekt?

- (a) Sie sind immer in den Labels vorhanden
- (b) Aufgaben-irrelevante Variablen sind durch Zufall mit relevanten Variablen in der Trainingsdistribution korreliert — das Modell kann auf ihnen basieren
- (c) Sie treten nur bei kleinen Datensätzen auf
- (d) Sie können aus den Testdaten gelesen werden

6. Wieviele Gewichte (ohne Bias) hat `torch.nn.Conv2d(3, 20, 5)`?

- (a) 300
- (b) 1500
- (c) 6000
- (d) 75

7. Was ist das Ziel der Aktivierungsmaximierung bei XAI?

- (a) Einen Input x^* zu finden, der einen spezifischen Ausgabe-Neuron maximal aktiviert: $x^* = \operatorname{argmax} f(x)$
- (b) Den Loss zu maximieren
- (c) Eine Attribution für jeden Feature zu berechnen
- (d) Adversarielle Robustheit zu messen

8. Was passiert mit dem Cell State c in einem LSTM, wenn alle Gates geschlossen sind?

- (a) c wird auf null gesetzt
- (b) c bleibt konstant — kein Schreiben, Lesen oder Löschen
- (c) c wird mit dem Input aktualisiert
- (d) c wird exponentiell abgeschwächt

2 Theorie (20 Punkte)

Abschluss-Theorieaufgabe zu Klassifikationslosses und Gradientenabstieg:

(a)

Vergleichen Sie 0/1-Loss, Perceptron Loss und Log-Loss in einer Tabelle (Formel, optimierbar via GD, Verhalten auf korrekt klassifizierten Punkten, Marginalisierung). (10 Pkt.)

Antwort:

(b)

Was bedeutet es, dass der Log-Loss als Regularisierer wirkt? Wie schiebt er die Entscheidungsgrenze weg von den Trainingsdaten? (5 Pkt.)

Antwort:

(c)

Warum ist Cross-Entropy ein natürlicher Loss für Klassifikation aus der Perspektive der Maximum-Likelihood-Schätzung? (5 Pkt.)

Antwort:

3 Theorie (20 Punkte)

Betrachten Sie CNN-Architekturen und Anwendungen:

(a)

Beschreiben Sie das YOLO-Verfahren für Object Detection. Was wird vorhergesagt? (6 Pkt.)

Antwort:

(b)

Was ist WaveNet und warum werden dilated causal convolutional layers verwendet? (7 Pkt.)

Antwort:

(c)

Was bedeutet 'kausal' in kausalen Faltungen, und warum ist diese Eigenschaft für Sprachgenerierung wichtig? (7 Pkt.)

Antwort:

4 Theorie (20 Punkte)

Betrachten Sie die vollständige Altklausur-Aufgabe zu RNNs:

(a)

Gegeben: $h_1 = \tanh(x_1 \blacksquare w + h_0)$, $h_2 = \tanh(x_2 \blacksquare w + h_1)$, $y = h_2$, $E = (y - t)^2$. Zeichnen Sie den annotierten Berechnungsgraphen. (5 Pkt.)

Antwort:

(b)

Berechnen Sie $\partial E / \partial y$ und $\partial E / \partial h_2$. (4 Pkt.)

Antwort:

(c)

Geben Sie die vollständige Kettenregel für $\partial E / \partial w$ an. Beachten Sie, dass w in h_1 und h_2 vorkommt. (6 Pkt.)

Antwort:

(d)

Berechnen Sie $\partial E / \partial w$ explizit. Welche Terme entstehen durch BPTT? (5 Pkt.)

Antwort:

5 Programmierung (20 Punkte)

Abschluss-Programmieraufgabe — Komplex:

(a)

Implementieren Sie in PyTorch ein Modell für Multi-Task Learning: gemeinsamer Feature-Extraktor (2 Linear-Layer, ReLU), dann zwei Köpfe — Kopf 1: Regression (1 Output, MSE Loss), Kopf 2: Binärklassifikation (1 Output, BCE Loss). (12 Pkt.)

Antwort:

(b)

Schreiben Sie den Forward Pass und die kombinierte Loss-Berechnung. Wie würden Sie die Gewichtung der beiden Losses festlegen? (8 Pkt.)

Antwort:
